

I Lemme d'Arden

On utilise $+$ à la place de $\cup$ et $|$.

Partie 1 — Lemme d'Arden

Dans cette partie, Σ est un alphabet et $K, L \in \mathcal{P}(\Sigma^*)$ sont deux langages sur cet alphabet. On y étudie l'équation $(E) : X = KX + L$ dont l'inconnue est le langage X .

1. Montrer que le langage K^*L est solution de l'équation (E) .

Solution

$KK^*L + L = K^+L + L = (K^+ + \varepsilon)L = K^*L$, donc K^*L est bien solution de (E) .

2. Montrer que toute solution X de (E) vérifie $K^*L \subseteq X$.

Solution

Montrons par récurrence sur $n \in \mathbb{N}$ que $K^nL \subseteq X$. On a $K^0L = L \subseteq KX + L = X$. Si $K^nL \subseteq X$, alors

$$K^{n+1}L = K(K^nL) \subseteq KX \subseteq KX + L = X.$$

Ainsi X contient $\bigcup_{n \in \mathbb{N}} K^nL = K^*L$.

Ces deux questions montrent que K^*L est la plus petite solution de (E) au sens de l'inclusion.

3. On suppose ici que $\varepsilon \notin K$. Montrer sous cette condition que toute solution X de (E) vérifie $X \subseteq K^*L$.

Solution

Supposons $X \setminus K^*L$ non vide et choisissons un mot m de cet ensemble de longueur minimale. Comme $m \in X = KX + L$ et $m \notin L$, il existe $k \in K$ et $m' \in X$ tels que $m = km'$. Si $m' \in K^*L$, alors $m \in KK^*L \subseteq K^*L$, contradiction. Donc $m' \in X \setminus K^*L$. Mais $\varepsilon \notin K$ donne $|k| > 0$, donc $|m'| < |m|$, ce qui contredit la minimalité de m .

4. Dédire des questions précédentes le lemme d'Arden : pour tout alphabet Σ , pour tous $L, K \in \mathcal{P}(\Sigma^*)$ tels que $\varepsilon \notin K$, l'équation $X = KX + L$ admet une unique solution, à savoir K^*L .

Solution

La question 1 donne l'existence. Si X est solution, les questions 2 et 3 donnent $K^*L \subseteq X$ et $X \subseteq K^*L$, donc $X = K^*L$, d'où l'unicité.

5. A-t-on toujours unicité de la solution à l'équation (E) si $\varepsilon \in K$? Justifier.

Solution

Non : pour $\Sigma = \{a\}$, $K = \{\varepsilon\}$ et $L = \{a\}$, les langages $\{a\}$ et a^* sont deux solutions distinctes de $X = KX + L$.

Partie 2 — Systèmes d'équations aux langages

Dans cette partie, $\Sigma = \{a, b\}$. On note L_1 le langage des mots ayant un nombre pair de b et L_2 celui des mots ayant un nombre impair de b . Si m est un mot et L un langage, on s'autorise l'abus de notation mL pour désigner la concaténation $\{m\}L$ et l'abus $m + L$ pour désigner l'union $\{m\} + L$.

6. Expliquer brièvement pourquoi (L_1, L_2) est solution du système suivant :

$$(S) : \begin{cases} L_1 = aL_1 + bL_2 + \varepsilon(1) \\ L_2 = aL_2 + bL_1 \quad (2) \end{cases}$$

Solution

Un mot de L_1 est vide, ou commence par a suivi d'un mot ayant un nombre pair de b , ou par b suivi d'un mot ayant un nombre impair de b . Donc $L_1 \subseteq \varepsilon + aL_1 + bL_2$. L'inclusion réciproque est immédiate. Un raisonnement similaire donne la seconde équation.

7. En utilisant le lemme d'Arden, résoudre le système (S) et en déduire une expression régulière pour L_1 et L_2 . *Indication : utiliser le lemme d'Arden sur (2) puis substituer dans (1).*

Solution

Comme $\varepsilon \notin \{a\}$, l'équation (2) donne $L_2 = a^*bL_1$ par le lemme d'Arden. En substituant dans (1) :

$$L_1 = (a + ba^*b)L_1 + \varepsilon.$$

Le langage $a + ba^*b$ ne contient pas ε . Le lemme d'Arden donne donc l'unique solution :

$$\begin{cases} L_1 = (a + ba^*b)^* \\ L_2 = a^*b(a + ba^*b)^* \end{cases}$$

8. Montrer que les expressions régulières $a^*b(a + ba^*b)^*$ et $(a + ba^*b)^*ba^*$ sont équivalentes et dénotent toutes les deux le langage L_2 .

Solution

Appliquons cette fois le lemme d'Arden à (1) : $L_1 = a^*(bL_2 + \varepsilon)$. En substituant dans (2), on obtient

$$L_2 = aL_2 + ba^*(bL_2 + \varepsilon) = (a + ba^*b)L_2 + ba^*.$$

Le lemme donne $L_2 = (a + ba^*b)^*ba^*$, puis

$$L_1 = a^*b(a + ba^*b)^*ba^* + a^*.$$

Les unicités garanties par le lemme d'Arden assurent que les deux expressions de l'énoncé dénotent bien le même langage L_2 .


Partie 3 — Langage reconnu par un automate

Le but de cette partie est de décrire une méthode permettant de déterminer le langage reconnu par un automate. Un automate est la donnée de $A = (\Sigma, Q, I, F, \delta)$, où Σ est un alphabet, Q un ensemble fini d'états, $I \subseteq Q$ et $F \subseteq Q$ les ensembles des états initiaux et finaux, et δ associe à $(q, a) \in Q \times \Sigma$ l'ensemble des états atteignables en lisant a depuis q . Son langage reconnu est

$$L(A) = \{u \in \Sigma^* \mid \exists q_0 \in I, \delta^*(q_0, u) \cap F \neq \emptyset\},$$

en étendant la fonction de transition des lettres aux mots.

Dans la question 9, on considère l'automate $A = (\{a, b\}, \{q_0, q_1, q_2\}, \{q_0\}, \{q_0, q_2\}, \delta)$ suivant :



Pour $i \in \{0, 1, 2\}$, on note $L_i = \{m \in \Sigma^* \mid \delta^*(q_i, m) \cap F \neq \emptyset\}$ le langage des mots qui font aboutir à un état final à partir de q_i . Déterminer $L(A)$ revient donc à déterminer L_0 .

9. La lecture de l'automate donne des liens entre L_0, L_1, L_2 . Par exemple, $L_0 = \varepsilon + aL_1$.

- Déterminer sans justification un système de trois équations liant L_0, L_1, L_2 .
- Résoudre ce système et en déduire le langage reconnu par A .


Solution

- Les transitions et états finaux donnent

$$\begin{cases} L_0 = \varepsilon + aL_1 \\ L_1 = aL_2 + bL_1 \\ L_2 = \varepsilon + (a + b)L_2 \end{cases}.$$

- Le lemme d'Arden donne successivement $L_2 = (a + b)^* = \Sigma^*$, $L_1 = b^*a\Sigma^*$ et $L_0 = \varepsilon + ab^*a(a + b)^*$. Le langage reconnu est L_0 .

10. En utilisant une méthode similaire, déterminer le langage reconnu par l'automate suivant :



Solution

Les langages associés aux trois états vérifient

$$\begin{cases} L_0 = aL_0 + aL_1 \\ L_1 = aL_1 + bL_0 + \varepsilon. \\ L_2 = bL_1 \end{cases}$$

Le lemme d'Arden donne $L_0 = a^*aL_1 = a^+L_1$. En substituant, $L_1 = (a + ba^+)L_1 + \varepsilon$, donc $L_1 = (a + ba^+)^*$. Ainsi $L_2 = b(a + ba^+)^*$ et $L_0 = a^+(a + ba^+)^*$. Les états initiaux étant q_0 et q_2 , le langage reconnu est

$$L_0 + L_2 = (a^+ + b)(a + ba^+)^*.$$

Remarque : cette méthode de détermination du langage reconnu par un automate n'est pas exigible au programme, mais peut être utile.

Partie 4 — Les langages reconnus sont réguliers

L'objectif est de prouver l'une des implications du théorème de Kleene : tout langage reconnaissable par un automate est régulier.

11. Montrer par récurrence sur $n \in \mathbb{N}^*$ le théorème suivant :

Soit $(K_{i,j})_{0 \leq i,j < n}$ un n^2 -uplet de langages sur un alphabet Σ dont aucun ne contient ε . Soit $(L_0, \dots, L_{n-1})$ un n -uplet de langages quelconques. Alors le système

$$X_i = \left(\sum_{j=0}^{n-1} K_{i,j} X_j \right) + L_i \quad \text{pour } 0 \leq i < n$$

d'inconnues $(X_0, \dots, X_{n-1})$ admet une unique solution. De plus, si les $K_{i,j}$ et L_i sont tous réguliers, les composantes X_i de cette unique solution sont également régulières.

Solution

Pour $n = 1$, il s'agit du lemme d'Arden ; K^*L est régulier si K et L le sont, par stabilité par étoile et concaténation.

Supposons le résultat établi à n inconnues et considérons un système à $n + 1$ inconnues. La dernière équation est

$$X_n = K_{n,n} X_n + \sum_{j=0}^{n-1} K_{n,j} X_j + L_n.$$

Comme $\varepsilon \notin K_{n,n}$, le lemme donne

$$X_n = K_{n,n}^* \left(\sum_{j=0}^{n-1} K_{n,j} X_j + L_n \right).$$

En substituant dans les n autres équations, on obtient

$$X_i = \sum_{j=0}^{n-1} K'_{i,j} X_j + L'_i,$$

avec $K'_{i,j} = K_{i,j} + K_{i,n} K_{n,n}^* K_{n,j}$ et $L'_i = L_i + K_{i,n} K_{n,n}^* L_n$. Aucun $K'_{i,j}$ ne contient ε . L'hypothèse de récurrence donne une unique solution $(X_0, \dots, X_{n-1})$, complétée de manière unique par la formule de X_n . La substitution est réversible, donc il s'agit bien de l'unique solution du système initial.

Si les coefficients sont réguliers, les $K'_{i,j}$ et L'_i le sont aussi. L'hypothèse de récurrence assure la régularité des n premières composantes ; la formule de X_n donne celle de la dernière par les stabilités usuelles.

12. Soit L un langage reconnaissable par un automate. En s'inspirant de la partie 3, montrer que L est l'une des composantes d'une solution d'un système d'équations aux langages qu'on déterminera et en déduire que L est régulier.

Solution

On peut supposer, par déterminisation, que l'automate qui reconnaît L possède un unique état initial q_0 . Notons ses états $q_0, \dots, q_{n-1}$. Pour chaque i , soit L_i le langage des mots qui mènent de q_i à un état final, et soit $B_i = \{\varepsilon\}$ si q_i est final, $B_i = \emptyset$ sinon. Alors $(L_0, \dots, L_{n-1})$ est solution de

$$X_i = \sum_{j=0}^{n-1} A_{i,j} X_j + B_i, \quad 0 \leq i < n,$$

où $A_{i,j} = \{a \in \Sigma \mid q_j \in \delta(q_i, a)\}$. Les B_i sont réguliers, et les $A_{i,j}$ sont des ensembles finis de lettres, donc réguliers et ne contenant pas ε . La question 11 montre que les composantes de cette solution sont régulières. En particulier, $L = L_0$ est régulier.

Remarque : cette preuve est constructive. La réciproque constitue l'autre implication du théorème de Kleene.

II Sujet 0 CCP

CCP · 2022 · MPI · oral

1. Rappeler la définition d'un langage régulier.

Solution

Sur un alphabet Σ , les langages réguliers forment la plus petite famille contenant les langages finis et stable par union, concaténation et étoile de Kleene.

2. Les langages suivants sont-ils réguliers ? Justifier.

- (a) $L_1 = \{a^n b a^m \mid n, m \in \mathbb{N}\}$ (c) $L_3 = \{a^n b a^m \mid n, m \in \mathbb{N}, n > m\}$
(b) $L_2 = \{a^n b a^m \mid n, m \in \mathbb{N}, n \leq m\}$ (d) $L_4 = \{a^n b a^m \mid n, m \in \mathbb{N}, n + m \equiv 0 \pmod{2}\}$

Solution

- (a) L_1 est régulier : il est dénoté par $a^* b a^*$.
(b) Supposons L_2 régulier. Par le théorème de Kleene, il est reconnaissable par un automate à $n \geq 1$ états. Soit $u = a^n b a^n \in L_2$; on a $|u| = 2n + 1 \geq n$. Soit $u = xyz$ la décomposition donnée par le lemme de l'étoile : $|xy| \leq n$, $y \neq \varepsilon$ et $xy^*z \subseteq L_2$. Comme les n premières lettres de u sont des a , on a $y = a^r$ pour un entier $r \geq 1$. Pour $k = 2$, on obtient


$$xy^2z = a^{n+r} b a^n \notin L_2,$$

puisque $n + r > n$. C'est absurde : L_2 n'est pas reconnaissable, donc n'est pas régulier.

- (c) On a $L_2 = L_1 \setminus L_3$. Si L_3 était régulier, la stabilité des langages réguliers par complément et intersection rendrait L_2 régulier, puisque L_1 l'est. Donc L_3 n'est pas régulier.
(d) La somme $n + m$ est paire si et seulement si n et m ont la même parité. Ainsi L_4 est régulier, dénoté par

$$(aa)^* b (aa)^* \mid a(aa)^* b a(aa)^*.$$


3. On considère l'automate non déterministe suivant :



- (a) Déterminiser cet automate.
(b) Construire une expression régulière dénotant le langage reconnu par cet automate.
(c) Décrire simplement avec des mots le langage reconnu par cet automate.

Solution

- (a) Avant la première lecture et après chaque lettre lue, on ajoute tous les états accessibles par zéro, une ou plusieurs ε -transitions, qui se franchissent sans lire de lettre.



(b) Une expression régulière est

$$a \mid (b \mid ab)(b \mid ab)^*(\varepsilon \mid a).$$

Depuis $\{0, 2\}$ ou $\{0, 2, 3\}$, la lecture de b ou de ab mène à $\{0, 2, 3\}$. Après au moins un de ces blocs, on peut s'arrêter dans $\{0, 2, 3\}$ ou lire un dernier a pour atteindre $\{1\}$. Le mot a est accepté directement depuis $\{0, 2\}$. Ce sont tous les chemins acceptants : depuis $\{1\}$, seule la lettre b permet d'éviter le puits $\emptyset$.

- (c) Le langage reconnu est l'ensemble des mots non vides sur $\{a, b\}$ ne contenant pas deux a consécutifs. En effet, après un a , on se trouve dans $\{1\}$; un autre a mène au puits. Toute lecture sans facteur aa reste dans $\{1\}$ ou $\{0, 2, 3\}$ dès la première lettre, et est donc acceptée. Le mot vide est rejeté puisque $\{0, 2\}$ n'est pas final.

III Palindromes et rationalité

Centrale · 2022 · MP

Soit $w \in \Sigma^*$. On note $\tilde{w}$ le mot obtenu à partir de w en inversant l'ordre des lettres et on dit que le mot w est un palindrome si $\tilde{w} = w$.

- Écrire une fonction `palindrome` de signature `string -> bool` qui teste, en temps linéaire, si un mot est un palindrome.

Solution

Corrigé à compléter.

Pour un alphabet Σ , on note $\text{Pal}(\Sigma)$ l'ensemble des palindromes de Σ^* .

- Montrer que si Σ est un alphabet à une lettre, alors $\text{Pal}(\Sigma)$ est régulier.

Solution

Corrigé à compléter.

- Montrer que si Σ contient au moins deux lettres, alors $\text{Pal}(\Sigma)$ n'est pas régulier. On pourra utiliser un automate et un mot de $\text{Pal}(\Sigma) \cap a^*ba^*$.

Solution

Corrigé à compléter.

Soit $L \subseteq \Sigma^*$ un langage reconnu par l'automate $A = (Q, I, F, T)$. Pour $(q, q') \in Q^2$, on note $L_{q, q'}$ le langage de tous les mots w qui étiquettent un chemin dans A partant de q et arrivant en q' .

- Montrer que $L_{q, q'}$ est reconnaissable et exprimer le langage L_A en fonction de langages $L_{q, q'}$.

Solution

Corrigé à compléter.

- Montrer que $\text{Pal}(\Sigma) \cap (\Sigma^2)^* = \{u\tilde{u} \mid u \in \Sigma^*\}$.

Solution

Corrigé à compléter.

Soit L un langage régulier reconnu par un automate $A = (Q, I, F, T)$. On définit les langages $D(L) = \{w\tilde{w} \mid w \in L\}$ et $R(L) = \{w \in \Sigma^* \mid w\tilde{w} \in L\}$.

6. Décrire simplement les langages $D(a^*b)$ et $R(a^*b^*a^*)$.

Solution

Corrigé à compléter.

7. Les langages $D(L)$ et $R(L)$ sont-ils reconnaissables ? On pourra faire intervenir les langages $L_{q,q'}$, définis ci-dessus.

Solution

Corrigé à compléter.

IV Ensembles inévitables de mots

ENS Ulm · 2019 · MP

On fixe l'alphabet $\Sigma = \{a, b\}$. Pour $w \in \Sigma^*$, on note $w = w_1 \dots w_n$, où $n = |w|$ est sa longueur. Le mot vide est noté ε . Un mot $s \in \Sigma^*$ est un facteur de w s'il existe deux mots $u, v \in \Sigma^*$ tels que $w = usv$. Autrement dit, s apparaît dans w en un bloc de lettres consécutives. En particulier, ε et w sont des facteurs de w .

Un mot w évite un mot s si s n'est pas un facteur de w . Il évite un ensemble $S \subseteq \Sigma^*$ s'il évite chacun de ses éléments.

0. Donner un mot de longueur au moins 12 qui évite

$$S_0 = \{aaaa, aaab, aba, baaa, bab, bbbb\}.$$

Solution

Le mot $(aabb)^3 = aabbaabbaabb$ convient. Ses facteurs de longueur 3 sont aab , abb , bba et baa ; ceux de longueur 4 sont $aabb$, $abba$, $bbaa$ et $baab$. Aucun ne figure dans S_0 .

1. Donner le pseudocode d'un algorithme simple qui détermine si un mot w évite un ensemble fini S . Analyser son coût en temps et en espace lorsque les m mots de S ont tous la même longueur ℓ .

Solution

On compare chaque motif à chaque position possible, sans extraire de sous-chaîne. Le pseudocode utilise des indices commençant à 0.

```
évite(w, S):
  n ← longueur(w)
  pour chaque s dans S:
    ℓ ← longueur(s)
    si ℓ = 0: renvoyer faux
    si ℓ ≤ n:
      pour i de 0 à n - ℓ inclus:
        j ← 0
        tant que j < ℓ et w[i + j] = s[j]:
          j ← j + 1
        si j = ℓ: renvoyer faux
  renvoyer vrai
```

Les tests du « tant que » sont évalués de gauche à droite, avec court-circuit. Pour $1 \leq \ell \leq n$, le temps au pire est $O(1 + m + m(n - \ell + 1)\ell)$, donc $O(nm\ell)$ si $m \geq 1$. L'espace auxiliaire est $O(1)$: seuls des indices sont conservés, sans compter les entrées. Si $\ell > n$, le temps est $O(1 + m)$. L'ensemble vide est toujours évité ; si $\varepsilon \in S$, aucun mot ne l'évite.

On pose

$$\text{Av}(S) = \{w \in \Sigma^* \mid w \text{ évite } S\}.$$

L'ensemble S est inévitable si $\text{Av}(S)$ est fini, et évitable sinon. Sur un alphabet fini, être évitable équivaut à admettre des mots évitants de longueurs arbitrairement grandes.

2. L'ensemble S_0 de la question 0 est-il inévitable ? Même question pour $S_1 = \{aaa, abb, baa, abab\}$.

Solution

Ils sont tous deux évitables. Pour tout $t \in \mathbb{N}$, $(aabb)^t$ évite S_0 , comme le montre la liste de facteurs de la question 0. De même, b^t évite S_1 , dont chaque élément contient au moins un a .

3. Montrer que $S_2 = \{aaa, bab, baab, bbb\}$ est inévitable. On pourra donner une borne sur la longueur des mots qui l'évitent.

Solution

Supposons qu'un mot de longueur 7 évite S_2 . Ses cinq premières lettres contiennent ba : sinon ce préfixe serait de la forme $a^i b^j$, avec $i \leq 2$ et $j \leq 2$ pour éviter aaa et bbb , donc de longueur au plus 4.

Cette occurrence de ba commence à une position $p \leq 4$; elle est donc suivie d'au moins deux lettres. La première doit être a , pour éviter bab . La suivante ne peut être ni a (facteur aaa), ni b (facteur $baab$). C'est impossible. Tout mot de longueur au moins 7 contient donc un facteur dans S_2 . La borne est optimale : $aabbaa$, de longueur 6, évite S_2 .

4. Soient maintenant un alphabet fini non vide Σ , de cardinal r , et un entier $k \geq 1$. Montrer que tout mot de longueur au moins $r^k + k$ possède deux occurrences distinctes d'un même facteur de longueur k . Autrement dit, il existe $1 \leq p < q \leq |w| - k + 1$ tels que $w_{p+j} = w_{q+j}$ pour tout $0 \leq j < k$.

Solution

Un mot de longueur n possède $n - k + 1$ positions où commence un facteur de longueur k , alors qu'il n'existe que r^k mots de cette longueur. Si $n \geq r^k + k$, le principe des tiroirs donne deux positions distinctes portant le même facteur. Les deux occurrences peuvent se chevaucher.

5. En déduire un algorithme qui détermine si un ensemble fini S est inévitable. Justifier sa terminaison et sa correction, puis donner sa complexité en temps et en espace. On ne demande pas un algorithme efficace.

Solution

Si S est vide, il est évitable puisque l'alphabet est non vide. Si $\varepsilon \in S$, il est inévitable. On suppose désormais S non vide et formé de mots non vides. Posons

$$k = \max_{s \in S} |s|, \quad L = \sum_{s \in S} |s|, \quad N = r^k + k.$$

Répétition et cycle. Considérons le graphe dont les sommets sont les mots de longueur k qui évitent S . Il existe une arête de u vers v si v s'obtient en supprimant la première lettre de u et en ajoutant une lettre à sa fin. Les facteurs successifs de longueur k d'un mot évitant S décrivent un chemin dans ce graphe.

Réciproquement, un chemin donne un mot évitant S : tout facteur interdit, de longueur au plus k , serait contenu dans l'une de ses fenêtres de longueur k . Un chemin qui répète un sommet contient un cycle ; en parcourant ce cycle autant de fois que voulu, on obtient des mots évitants arbitrairement longs. Cet argument vaut aussi lorsque les deux occurrences se chevauchent.

Par la question 4, un mot évitant de longueur N fournit un tel cycle. Ainsi,

$$S \text{ est inévitable} \iff \text{aucun mot de longueur } N \text{ n'évite } S.$$

Il suffit donc d'énumérer les r^N mots de longueur exactement N et de les tester avec l'algorithme de la question 1. Un seul témoin évitant suffit pour répondre « évitable ».

Le coût au pire est $O(r^N N L)$ en temps et $O(N)$ en espace auxiliaire, en générant un seul mot à la fois. Pour $r \geq 2$ fixé, cette borne en temps est doublement exponentielle en k . Le stockage des entrées est exclu.

Amélioration. On peut construire directement le graphe précédent et y chercher un cycle par parcours en profondeur. Il possède au plus r^k sommets et r^{k+1} arêtes ; une fois le graphe construit, ce parcours coûte $O(r^k + r^{k+1})$. Il faut aussi compter la construction, notamment les tests d'évitement des sommets, qui coûtent $O(r^k k L)$ avec la méthode naïve.

6. Une expression régulière e est dite inévitable si son langage $L(e)$ est un ensemble inévitable. Donner un exemple dont le langage ne contient pas le mot vide.

Solution

L'expression $e = aaa \mid bab \mid baab \mid bbb$ convient, d'après la question 3. Il n'est pas nécessaire d'ajouter une étoile : celle-ci ferait appartenir ε au langage et rendrait l'inévitabilité immédiate.

7. Une expression régulière e est bornée s'il existe $n \in \mathbb{N}$ tel que tout mot de $L(e)$ soit de longueur au plus n . Si e est bornée, comment déterminer si elle est inévitable ?

Solution

Sur un alphabet fini, un langage borné est fini. On peut donc énumérer $L(e)$ puis appliquer la question 5.

Pour rendre cette énumération effective sans connaître de borne à l'avance, on construit un automate déterministe pour $L(e)$ et on ne conserve que les états utiles, accessibles depuis l'état initial et depuis lesquels un état final est accessible. Le graphe utile est acyclique puisque le langage est fini. On énumère ses chemins acceptants et les mots qu'ils portent. Si aucun état final n'est accessible, le langage est vide.

8. Expliquer comment déterminer si une expression régulière quelconque e est inévitable.

Solution

Les mots qui contiennent un facteur de $L(e)$ forment le langage régulier

$$B = \Sigma^* L(e) \Sigma^*.$$

On construit un automate pour B , on le détermine, puis on le complète sur Σ avant d'échanger états finaux et non finaux. On obtient un automate déterministe complet A reconnaissant

$$\text{Av}(L(e)) = \Sigma^* \setminus B.$$

On conserve les états utiles de A . Son langage est infini si et seulement si ce graphe utile contient un cycle : un cycle utile peut être répété sur un chemin acceptant ; réciproquement, un chemin acceptant assez long répète un état. Chaque arête consomme ici une lettre.

L'expression e est donc inévitable si et seulement si le graphe utile est acyclique. Les recherches d'accessibilité et de cycle sont linéaires dans la taille de l'automate obtenu ; la détermination peut produire un nombre d'états exponentiel dans la taille de l'automate initial.

9. On dit que S est inévitable relativement à e si seuls un nombre fini de mots de $L(e)$ évitent S , c'est-à-dire si

$$L(e) \cap \text{Av}(S)$$

est fini. Étant donnés e et un ensemble fini S , expliquer comment décider cette propriété, ainsi que la propriété opposée.

Solution

On construit un automate déterministe pour $L(e)$ et un automate déterministe complet pour $\text{Av}(S)$, comme à la question 8 en remplaçant $L(e)$ par l'union finie des mots de S .

Leur automate produit reconnaît $L(e) \cap \text{Av}(S)$: une paire d'états est finale lorsque ses deux composantes le sont. Après suppression des états inutiles, un cycle existe si et seulement si cette intersection est infinie. Son absence caractérise donc l'inévitabilité relative.

La propriété opposée signifie qu'une infinité de mots de $L(e)$ évitent S . Si $L(e)$ est fini, tout ensemble S est inévitable relativement à e selon la définition retenue ici.

10. Montrer que tout ensemble inévitable $S \subseteq \Sigma^*$, même infini, contient un sous-ensemble fini inévitable.

Solution

Si $\varepsilon \in S$, on prend $S' = \{\varepsilon\}$. Sinon, ε évite S ; l'ensemble fini $\text{Av}(S)$ est donc non vide. Notons n la longueur maximale de ses éléments.

Chaque mot u de longueur $n + 1$ possède un facteur $s_u \in S$. On choisit un tel facteur pour chacun de ces mots et on pose

$$S' = \{s_u \mid u \in \Sigma^{n+1}\}.$$

Cet ensemble est fini, inclus dans S et inévitable : tout mot de longueur au moins $n + 1$ possède un préfixe de longueur $n + 1$, qui contient l'un des facteurs choisis. Il ne reste qu'un nombre fini de mots plus courts.

11. Étant donnée une expression régulière inévitable e , expliquer comment calculer un sous-ensemble fini inévitable de $L(e)$.

Solution

On commence par tester si $\varepsilon \in L(e)$; dans ce cas, $\{\varepsilon\}$ est une réponse. Sinon, l'automate de la question 8 reconnaît un langage fini non vide, celui des mots évitant $L(e)$.

Son graphe utile est un graphe orienté acyclique. Un calcul de plus long chemin dans un ordre topologique donne la longueur maximale n d'un mot accepté. On énumère alors les mots u de longueur $n + 1$; pour chacun, on énumère ses facteurs et on en retient un accepté par un automate de $L(e)$. Un tel facteur existe par définition de n .

L'ensemble des facteurs retenus, après suppression des doublons, est une réponse par la question 10. Toutes les énumérations sont finies ; l'algorithme termine, même si son coût peut être très élevé. Le sous-ensemble obtenu n'est pas nécessairement de cardinal minimal.